

ESTRATÉGIAS EVOLUTIVAS (EE)

Cristiano Leite de Castro

crislcastro@ufmg.br

Departamento de Engenharia Elétrica
Universidade Federal de Minas Gerais
Belo Horizonte, Brasil

- Estratégias Evolutivas (*Evolution Strategies*) constituem uma classe de algoritmos evolutivos usados principalmente em otimização numérica.
- Estudos préliminares envolvendo EE foram desenvolvidos nos anos 60 na Alemanha: *Rechenberg* and *Schwefel*;



Rechenberg e Schwefel (1960)

- **características gerais:**
 - rápida convergência;
 - excelente desempenho para problemas de otimização numérica (variáveis reais);
 - seleção determinística de sobreviventes (baseada em *aptidão*)
 - seleção aleatória dos pais (não é baseada em *aptidão*);
 - **característica especial:** autoadaptação de parâmetros (coevolução);

Representação	Vetores reais
Recombinação	Discreta ou intermediária
Mutação	Gaussiana
Seleção para reprodução	Aleatória uniforme
Seleção para sobrevivência	(μ, λ) ou $(\mu + \lambda)$
Característica especial	Autoadaptação de atributos da mutação

Dada uma EE com uma população de μ indivíduos que produzem λ descendentes:

- ▶ $ES(\mu+\lambda)$: μ indivíduos geram λ filhos; do total de $\mu+\lambda$ soluções, os μ melhores são selecionados para a próxima geração;
- ▶ $ES(\mu,\lambda)$: μ indivíduos geram λ filhos; das λ novas soluções, os μ melhores são selecionados para a próxima geração – requer $\mu < \lambda$.

Representação

- ▶ Minimização de uma função n-dimensional $f: \mathbb{R}^n \rightarrow \mathbb{R}$
- ▶ Um indivíduo na estratégia evolutiva é composto pela variáveis de otimização e os parâmetros da estratégia:

$$\begin{aligned} a &= \langle x | \sigma | \alpha \rangle \\ &= \langle x_1, \dots, x_n | \sigma_1, \dots, \sigma_n | \alpha_1, \dots, \alpha_{n(n-1)/2} \rangle \end{aligned}$$

Na sequência, tem-se:

- ▶ Codificação do vetor solução candidata;
- ▶ Tamanhos de mutação;
- ▶ Ângulos de rotação da matriz de covariância (representam interações entre os σ_i);
- ▶ Outros componentes podem ser considerados.

- o formato do cromossomo (indivíduo) depende do tipo da estratégia de evolução selecionada:
 - Auto-adaptativa com tamanho de passo único (global):

$$\vec{a} = ((x_1, \dots, x_n), \sigma)$$

- Auto-adaptativa com n tamanhos de passo:

$$\vec{a} = ((x_1, \dots, x_n), (\sigma_1, \dots, \sigma_n))$$

- Auto-adaptativa correlacionada:

$$\vec{a} = ((x_1, \dots, x_n), (\sigma_1, \dots, \sigma_n), (\alpha_1, \dots, \alpha_{n(n-1)/2}))$$

Esquema Geral

- ▶ **Autoadaptação** – o desvio padrão é parte do indivíduo, e o tamanho da mutação evolui juntamente com a solução do problema de otimização:

$$\langle x_t | \sigma_t \rangle \rightarrow \langle x_{t+1} | \sigma_{t+1} \rangle$$

$$\sigma_{t+1} = \sigma_t \exp [N(0, \delta)]$$

$$\delta \propto \sqrt{\frac{1}{n}}$$

$$x_{t+1} = x_t + N(0, \sigma_{t+1} I)$$

- ▶ **A ordem é importante:** primeiro perturba-se σ , em seguida usa-se esse valor para perturbar a solução.

Lógica de Funcionamento

- ▶ A solução é avaliada explicitamente na função-objetivo.
- ▶ O tamanho da mutação é avaliado implicitamente:
 - se o σ usado é bom, então ele tende a gerar uma boa solução que por sua vez tem um bom valor de função.
- ▶ Reverter a ordem não faz sentido!
- ▶ A nova solução gerada compete com as μ existentes pela sobrevivência.

Estratégia (1)


Mutação descorrelacionada com um desvio padrão:

$$\langle x_t | \sigma_t \rangle \rightarrow \langle x_{t+1} | \sigma_{t+1} \rangle$$

$$\sigma_{t+1} = \sigma_t \exp [N(0, \delta)]$$

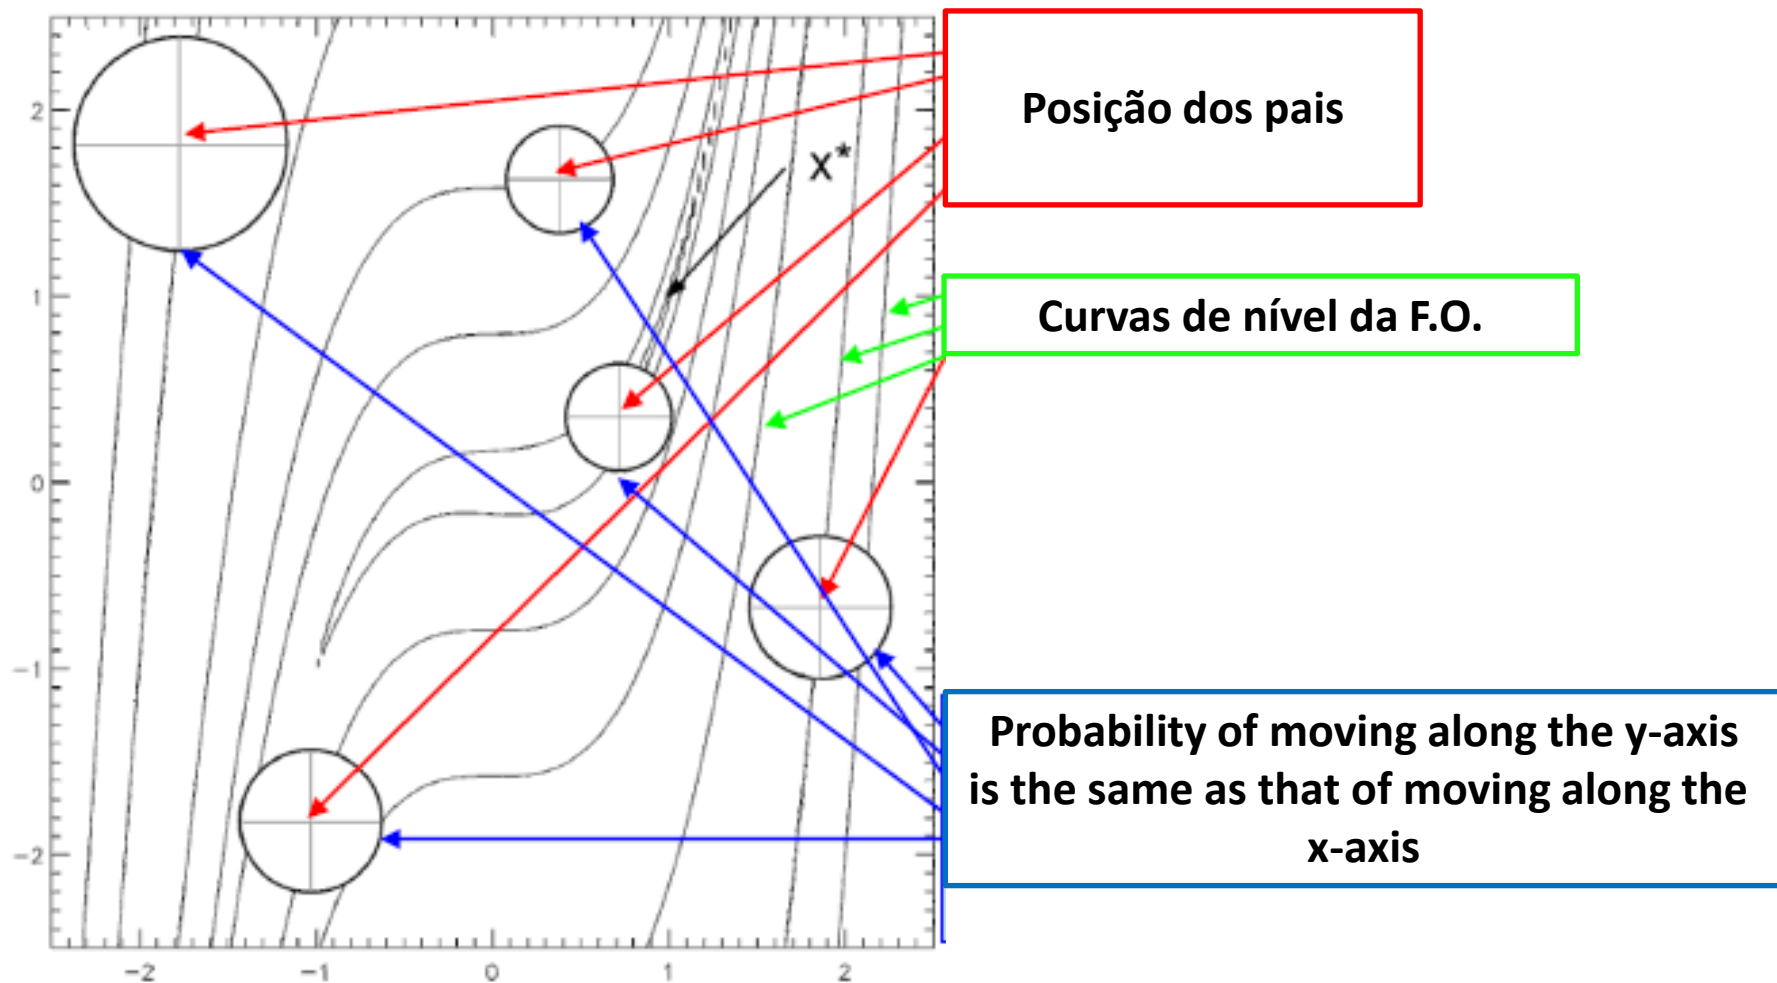
$$\delta \propto \sqrt{\frac{1}{n}}$$

$$x_{t+1} = x_t + N(0, \sigma_{t+1} I)$$



Exemplo Ilustrativo

- **mutação descorrelacionada com 1 desvio-padrão:**





Mutação descorrelacionada com n desvios padrão:

$$\langle x_t | \sigma_t \rangle \rightarrow \langle x_{t+1} | \sigma_{t+1} \rangle \quad \sigma_{t+1,i} = \sigma_{t,i} \exp [N(0, \tau_1) + N(0, \tau_2)]$$

$$x_{t+1,i} = x_{t,i} + N(0, \sigma_{t+1,i} I)$$

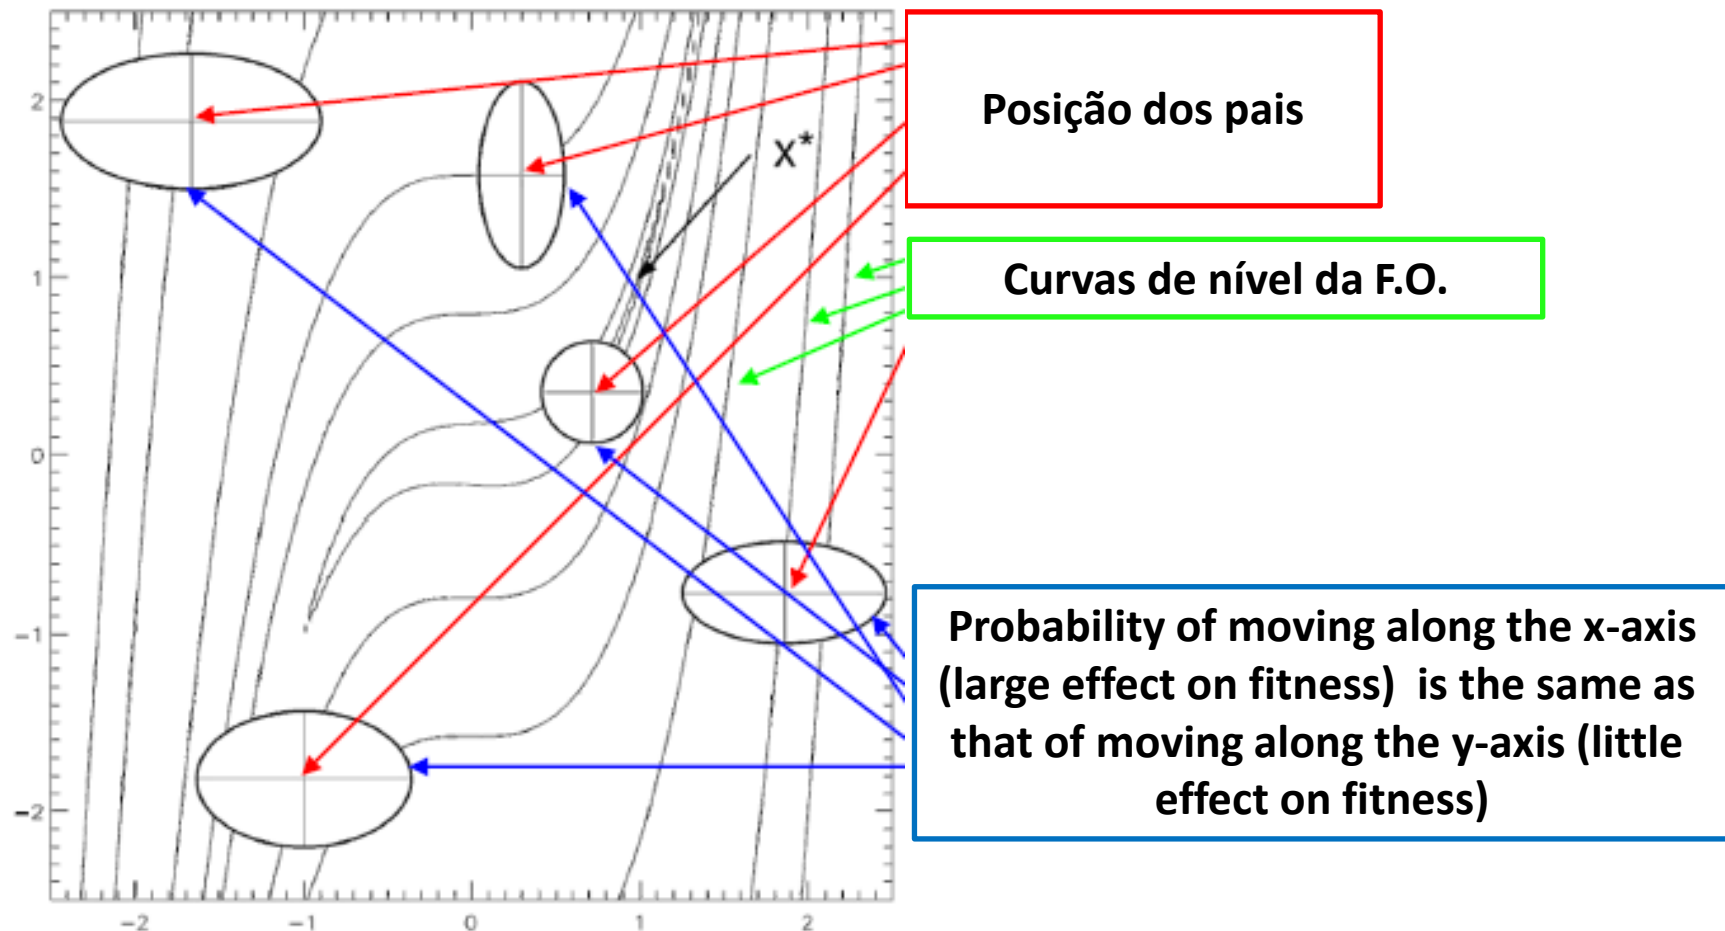
$$\tau_1 \propto \frac{1}{\sqrt{2n}}$$

$$\tau_2 \propto \frac{1}{\sqrt{2\sqrt{n}}}$$



Exemplo Ilustrativo

- **mutação descorrelacionada com n desvios-padrão:**






Mutação correlacionada com n desvios padrão e ângulos de rotação:

$$\langle x_t | \sigma_t | \alpha_t \rangle \rightarrow \langle x_{t+1} | \sigma_{t+1} | \alpha_{t+1} \rangle$$

$$\sigma_{t+1,i} = \sigma_{t,i} \exp [N(0, \tau_1) + N(0, \tau_2)]$$

$$\alpha_{t+1,i} = \alpha_{t,i} + \beta N(0, 1)$$

$$x_{t+1} = x_t + N(0, C(\sigma_{t+1}, \alpha_{t+1}))$$




Mutação correlacionada com n desvios padrão e ângulos de rotação:

$$\langle x_t | \sigma_t | \alpha_t \rangle \rightarrow \langle x_{t+1} | \sigma_{t+1} | \alpha_{t+1} \rangle$$

$$\sigma_{t+1,i} = \sigma_{t,i} \exp [N(0, \tau_1) + N(0, \tau_2)]$$

$$\alpha_{t+1,i} = \alpha_{t,i} + \beta N(0,1)$$

$$x_{t+1} = x_t + N(0, C(\sigma_{t+1}, \alpha_{t+1}))$$



$$c_{ii} = \sigma_i^2$$



$$c_{ij, i \neq j} = \begin{cases} 0 & \text{sem correlações} \\ 0.5(\sigma_i^2 - \sigma_j^2) \tan(2\alpha_{ij}) & \text{correlações} \end{cases}$$

$$\tan(2\alpha_{ij}) = \frac{2c_{ij}}{\sigma_i^2 - \sigma_j^2}$$

$$\beta \approx 5^\circ$$

Gaussiana Multivariada

$$\vec{N}(\vec{\mu}, C) = f_X(\vec{x}) = \frac{1}{(2\pi)^{n/2} |C|^{1/2}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})' C^{-1} (\vec{x} - \vec{\mu})\right)$$



$\vec{\mu}$ = vetor de médias

C = matriz de covariância

$|C|$ = determinante de C

C^{-1} = inversa de C

Matriz de Covariância

$$C = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \cdots & \sigma_{nn} \end{bmatrix}$$

C: simétrica e definida positiva

σ_{ii} : variâncias de cada variável x_i

σ_{ij} : covariância entre as variáveis x_i e x_j

$\sigma_{ij} > 0 \rightarrow$ Ex: x_i = comprimento e x_j = peso

$\sigma_{ij} < 0 \rightarrow$ Ex: x_i = venda de carro e x_j = índice de desemprego


$\sigma_{ij} = 0 \rightarrow x_i$ e x_j são estatisticamente independentes

Se a matriz de covariância é diagonal, então $\vec{N}(\vec{\mu}, C)$ se reduz ao produto de distribuições normais univariadas para cada componente x_i

Matriz de Covariância


- Interpretação dos ângulos de rotação entre cada par de variáveis:

$$c_{ij(i \neq j)} = \frac{1}{2}(\sigma_i^2 - \sigma_j^2) \tan(2\alpha_{ij})$$



Exemplo Ilustrativo

- mutação correlacionada com n desvios-padrão e ângulos de rotação:



Recombinação

- ▶ A recombinação atua tanto nas variáveis de otimização quanto nos parâmetros da estratégia.
- ▶ O procedimento de recombinação em EEs difere do cruzamento típico em algoritmos genéticos.
- ▶ Notação $ES(\mu/\rho, \lambda)$ ou $ES(\mu/\rho+\lambda)$:
 - indica quantos pais são usados na operação de recombinação – ρ pais são selecionados aleatoriamente e formam um filho que, em seguida, sofre mutação.
- ▶ **Local recombination:** ($\rho=2$) um filho é criado a partir da recombinação de dois pais selecionados aleatoriamente entre os μ pais presentes na população.
- ▶ **Global recombination:** ($2 < \rho \leq \mu$) mais de dois pais são selecionados aleatoriamente para produzir um único filho.
- ▶ **No recombination:** ($\rho=1$)

Recombinação


	LOCAL: Two fixed parents	GLOBAL: Multi-parent (more used)
INTERMEDIARY:	Local intermediary	Global intermediary
DISCRETE:	Local discrete	Global discrete

Obs.: According to Eiben & Smith:

- Discrete recombination is more used for the variable part of chromosome;
- Intermediary recombination is more used for parameter part of chromosome;

Recombinação Discreta

- ▶ **Discrete recombination:** Os alelos dos pais são usados para gerar um filho. Para cada componente que compõe o filho, um dos ρ pais é selecionado aleatoriamente e o componente correspondente é herdado deste.




Recombinação Discreta Local

- Variable at position i will be copied at random (uniformly distr.) from parent 1 or parent 2, position i .



Recombinação Discreta Global

– Considers all parents $\rho = \mu$




Recombinação Intermediária

- **Intermediate recombination:** Os valores médios dos alelos dos pais são usados para gerar um filho.


$$\chi_{t,k} = \langle x_{t,k} | \sigma_{t,k} | \alpha_{t,k} \rangle$$

$$\chi_{t,k} = \left\langle \frac{1}{\rho} \sum_{i=1}^{\rho} x_{t,i} \middle| \frac{1}{\rho} \sum_{i=1}^{\rho} \sigma_{t,i} \middle| \frac{1}{\rho} \sum_{i=1}^{\rho} \alpha_{t,i} \right\rangle$$




Recombinação Interm. Local

- Variable at position i is arithmetic mean of Parent 1 and Parent 2, position i .



Recombinação Interm. Global



Considerações:

- ▶ EEs frequentemente usam recombinação global.
- ▶ Recombinação discreta é recomendada para as variáveis de otimização:
 - Preserva diversidade na população.
- ▶ Recombinação intermediária é recomendada para os parâmetros de otimização:
 - Assegura uma autoadaptação de parâmetros mais cautelosa.

- ▶ Seleção para reprodução: seleção com distribuição uniforme de probabilidades, ou seja, não polarizada.
- ▶ Seleção para sobrevivência: Aplicado aos λ filhos criados após recombinação e mutação. Os μ pais da próxima geração são selecionados:
 - ▶ (1) entre os λ filhos;
 - ▶ (2) ou entre a união dos μ pais e dos λ filhos.



- Seleção ($\mu+\lambda$):
 - μ pais produzem λ filhos por recombinação + mutação
 - os melhores μ indivíduos do total ($\mu+\lambda$) são selecionados para sobreviver
 - seleção determinística baseada em *fitness (ranking)*.
 - garante que não haja deterioração:
 - o melhor indivíduo na geração t sempre estará na geração $t+1$ (Estratégia Elitista).

- Seleção (μ, λ) :
 - μ pais produzem $\lambda \gg \mu$ filhos por
 - recombinação + mutação
 - os melhores μ indivíduos de λ descendentes são selecionados para sobreviver:
 - seleção determinística baseada em *fitness*.
 - não garante comportamento monotônico do *fitness*:
 - o melhor valor de *fitness* na geração $t+1$ pode ser pior que na geração t ;

Exemplo Ilustrativo

Operators: Selection



- Example: (2,3)-Selection




Parents don't survive ...
Parents don't survive!
... but a worse offspring.



- Example: (2+3)-Selection



... now this offspring survives.



- em geral, (μ, λ) é preferida sobre $(\mu + \lambda)$ devido as seguintes razões:
 - (μ, λ) descarta todos os pais e por isso ela é mais propensa a escapar de ótimos locais. Isso é vantajoso em superfícies multimodais;
 - Se a função objetivo é dinâmica (muda no tempo), $(\mu + \lambda)$ preserva soluções desatualizadas, não sendo capaz de acompanhar a dinâmica da superfície;
 - $(\mu + \lambda)$ tende a dificultar o mecanismo de coevolução, pois parâmetros mal adaptados podem sobreviver por um número grande de gerações quando um indivíduo possui boas variáveis de decisão e parâmetros de estratégia ruins.

- ▶ A relação λ/μ controla a pressão seletiva, e quanto maior a relação, maior a pressão seletiva para sobrevivência.
- ▶ Em geral recomenda-se $\lambda/\mu = 7$ (e.g., $\mu = 15$ e $\lambda = 100$).

```
Criar uma população inicial  $X[t]$ ;  
Inicializar os parâmetros de estratégia;  
  
Enquanto critério de parada não satisfeito faça:  
    para  $i=1, \dots, \lambda$  faça  
        Escolha  $\rho$  pais aleatoriamente;  
        Faça recombinação para gerar  $z$ ;  
        Faça mutação nos parâmetros da estratégia;  
         $z \leftarrow z + \text{mutação}$ ;  
        Avalie  $f(z)$ ;  
    fimpara  
    Aplique seleção ES ( $\mu/\rho, \kappa, \lambda$ )  
     $t \leftarrow t+1$ ;  
Fimenquanto
```

- **Leitura Recomendada:**

- Capítulo 4 do Livro:

A.E. EIBEN, J.E. SMITH, Introduction to Evolutionary Computing (Natural Computing Series), Springer.

